Laporan Proyek Data Science Menggunakan Metodologi CRISP-DM

A. Business Understanding (Pemahaman Bisnis)

Pada tahap awal ini, fokus utama adalah memahami permasalahan yang ingin diselesaikan. Proyek ini bertujuan untuk **memprediksi jenis wilayah (Perkotaan atau Perdesaan)** berdasarkan beberapa indikator pendidikan yang tersedia dalam dataset *Rapor Publik Asesmen Nasional*.

Tujuan Proyek

- Mengembangkan model machine learning yang mampu mengklasifikasikan jenis wilayah sekolah.
- Membantu pemangku kebijakan atau peneliti dalam melakukan analisis kondisi pendidikan berdasarkan karakteristik wilayah.

B. Data Understanding (Pemahaman Data)

Dataset yang digunakan bernama **raporPublikAsesmenNasional.csv**, yang berisi informasi mengenai beberapa indikator hasil Asesmen Nasional.

Sumber Data: https://data.kemendikdasmen.go.id/dataset/p/asesmen nasional/rapor-publik-asesmen-nasional-2024-kepala-satuan-pendidikan-2024-indonesia

Isi Dataset (Contoh Kolom)

- Npsn
- nama_satuan_pendidikan
- kabupaten_kota
- provinsi
- status_sekolah
- kategori_wilayah (target)
- Indikator nilai seperti literasi, numerasi, dan karakter lainnya.

C. Data Preparation (Persiapan Data)

1. Menghapus data duplikat

   Beberapa baris data yang identik dihapus agar tidak memengaruhi hasil training.

2. Menangani nilai kosong

   Untuk kolom numerik → diisi dengan median atau mean. Untuk kolom kategorikal → diisi kategori terbanyak (mode).

3. Menangani outlier

   Memeriksa fitur jumlah siswa, jumlah guru, rasio, dan fitur-fitur indikator lain untuk memastikan tidak ada nilai ekstrem yang merusak model.

4. Encoding data kategorikal

   Mengubah kategori menjadi angka menggunakan:

   - Label Encoding
   - One Hot Encoding (jika diperlukan)

   Contoh yang di-encode: kurikulum, jenis_sek, status sekolah, internet/listrik.

5. Normalisasi (opsional)

   Karena Random Forest tidak terlalu sensitif terhadap skala, normalisasi hanya diterapkan jika ada fitur tertentu yang perbedaannya terlalu besar.

D. Modeling (Pemodelan)

Algoritma yang digunakan adalah Random Forest Classifier, karena cocok untuk dataset dengan banyak fitur numerik dan kategorikal, serta menghasilkan performa yang stabil.

Langkah-langkah pemodelan:

1. Membagi data menjadi training dan testing (80:20).
2. Melatih model Random Forest menggunakan data training.
3. Mengatur parameter seperti jumlah tree, depth, dan criterion jika diperlukan.
4. Melakukan prediksi pada data testing.

5. Menyimpan model terbaik untuk evaluasi.

Alasan pemilihan Random Forest:

1. Tahan terhadap noise dan missing value kecil
2. Tidak membutuhkan scaling
3. Bisa menangani fitur numerik dan kategorikal
4. Menghasilkan feature importance untuk melihat faktor paling berpengaruh
5. Umumnya akurat di dataset pendidikan

E. Evaluation (Evaluasi)

Pada tahap evaluasi, performa model diuji menggunakan tiga metode utama, yaitu Accuracy Score, Confusion Matrix, dan Classification Report.

- **Accuracy Score** digunakan untuk melihat seberapa besar persentase prediksi model yang benar.
- **Confusion Matrix** digunakan untuk mengetahui distribusi prediksi benar dan salah pada tiap kelas (Urban dan Rural).
- Sedangkan **Classification Report** memberikan informasi lebih detail melalui nilai Precision, Recall, dan F1-Score sehingga dapat terlihat apakah model bekerja seimbang untuk kedua kelas.

Hasil evaluasi dari ketiga metode ini membantu memastikan bahwa model Random Forest dapat memprediksi jenis wilayah sekolah secara akurat dan tidak bias ke salah satu kelas.

F. Deployment (Penerapan / Implementasi)

Model akan di-deploy menggunakan Gradio sehingga dapat digunakan dengan mudah.

Desain Interface Gradio:

Bagian Input (yang diisi oleh pengguna)

Ini semacam form berisi kolom-kolom yang bisa diisi, misalnya:

- jumlah peserta didik
- jumlah pendidik
- proporsi guru S1

- kurikulum
- status sekolah
- indikator mutu (misal APK, BBS, COP, dll)

Pengguna akan memasukkan angka atau memilih kategori di setiap kolom.

Tombol “Prediksi”

Setelah data diisi, pengguna menekan tombol Submit / Predict.

Bagian Output (hasil dari model)

Setelah tombol ditekan, model akan menampilkan:

- Prediksi wilayah sekolah → Urban / Rural
- Probabilitas prediksi
- Fitur yang paling berpengaruh terhadap prediksi (feature importance)

LAMPIRAN

1. Sumber Dataset

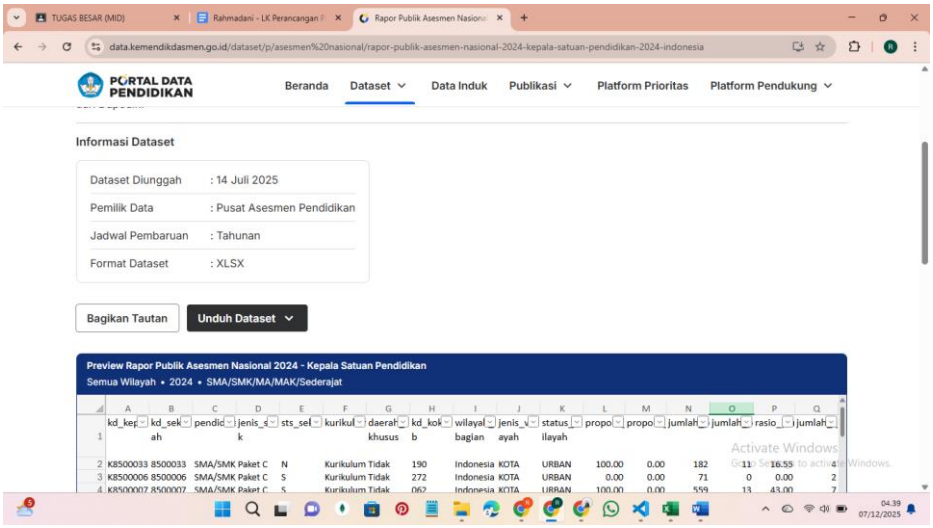

2. Struktur File & Folder

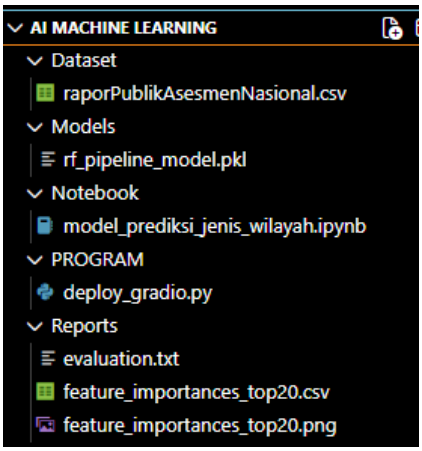

3. Notebook/model_prediksi_jenis_wilayah.ipynb

- **Import Library Utama untuk Proyek Klasifikasi Random Forest**

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import os

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import OneHotEncoder, LabelEncoder
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix
from sklearn.ensemble import RandomForestClassifier
```

Kode ini bagian paling atas yang berisi semua import library standar yang dibutuhkan sepanjang proyek: pandas, numpy,

matplotlib+seaborn untuk visualisasi, scikit-learn untuk preprocessing (encoder, imputer, splitter), metrik evaluasi (accuracy, classification report, confusion matrix), sampai RandomForestClassifier sendiri.

- **Pengecekan Sumber Data**

```
DATA_PATH = "../Dataset/raporPublikAsesmenNasional.csv"

print("Dataset exists:", os.path.exists(DATA_PATH))

✓ 0.0s

Dataset exists: True
```

Kode ini hanya mendefinisikan lokasi file CSV dataset (raporPublikAsesmenNasional.csv) dan langsung mengecek apakah file-nya benar-benar ada di folder Dataset. Kalau ada, muncul tulisan "Dataset exists: True". Fungsinya supaya saat buka notebook, langsung tahu data sudah siap atau belum, biar gak error pas load data nanti.

- **Load Dataset dan Tampilkan 5 Baris Pertama**

```
df = pd.read_csv(DATA_PATH, sep=';')
df.head()
```

	kd_kepsek_an	kd_sekolah	pendidikan_sederajat	jenis_sek	sts_sek	kurikulum	daerah_khusus	kd_kokab	wilayah_bagian	jenis_wilayah	...	SMK_KPL	SMK_PBEL	SMK_PIM	SMK_PKL	SMK_PKUR	SMK-SARPRAS	SMK_TEFA	SSV	TOC	TOR
0	K8500033	8500033	SMA/SMK/MA	Paket C	N	Kurikulum Merdeka	Tidak	190	Indonesia Barat	KOTA	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	57,97	36,05	53,50
1	K8500006	8500006	SMA/SMK/MA	Paket C	S	Kurikulum 2013	Tidak	272	Indonesia Barat	KOTA	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	52,20	35,16	62,48
2	K8500007	8500007	SMA/SMK/MA	Paket C	S	Kurikulum Merdeka	Tidak	62	Indonesia Barat	KOTA	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	61,35	36,05	60,14
3	K8500008	8500008	SMA/SMK/MA	Paket C	S	Kurikulum Merdeka	Tidak	104	Indonesia Barat	KABUPATEN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	75,98	33,18	37,70
4	K8500005	8500005	SMA/SMK/MA	Paket C	S	Kurikulum Merdeka	Tidak	59	Indonesia Barat	KABUPATEN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN	47,90	30,85	43,90

5 rows × 79 columns

Kode ini membaca file CSV raporPublikAsesmenNasional.csv (dengan pemisah titik koma) menggunakan pandas, lalu langsung menampilkan 5 baris pertama dengan df.head(). Tujuannya supaya kita bisa lihat sekilas isi data: ada kolom kode sekolah, status wilayah (KOTA/KABUPATEN), bentuk sekolah, jumlah siswa, skor AN, dll.

- **Eksplorasi Data Awal**

```
print(df.shape)
df.info()
df.describe()
```

```
(1478, 79)
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1478 entries, 0 to 1477
Data columns (total 79 columns):
 #   Column                       Non-Null Count  Dtype
---  ------                       --------------  -----
 0   kd_kepsek_an                 1478 non-null   object
 1   kd_sekolah                   1478 non-null   int64
 2   pendidikan_sederajat         1478 non-null   object
 3   jenis_sek                    1478 non-null   object
 4   sts_sek                      1478 non-null   object
 5   kurikulum                    1364 non-null   object
 6   daerah_khusus                1478 non-null   object
 7   kd_kokab                     1478 non-null   int64
 8   wilayah_bagian               1478 non-null   object
 9   jenis_wilayah                1478 non-null   object
 10  status_wilayah               1478 non-null   object
 11  proporsi_pendidik_min_s1     1364 non-null   object
 12  proporsi_pendidik_sertifikasi  1364 non-null   object
 13  jumlah_peserta_didik         1364 non-null   float64
 14  jumlah_pendidik              1364 non-null   float64
 15  rasio_pendidik_peserta_didik  1364 non-null   object
 16  jumlah_r_kelas               1364 non-null   float64
 17  ketersediaan_internet        1364 non-null   object
 18  ketersediaan_listrik         1364 non-null   object
...
 77  TOC                          1096 non-null   object
 78  TOR                          1091 non-null   object
dtypes: float64(8), int64(2), object(69)
memory usage: 912.3+ KB
```

	kd_sekolah	kd_kokab	jumlah_peserta_didik	jumlah_pendidik	jumlah_r_kelas	jumlah_komp_milik	jumlah_perpus	jumlah_rombel	jumlah_siswa_rombel	jumlah_siswa_penerima_PIP
count	1.478000e+03	1478.000000	1364.000000	1364.000000	1364.000000	1364.000000	1364.000000	1364.000000	1364.000000	1364.000000
mean	6.378087e+06	252.335589	379.151760	26.032991	14.236804	6.425953	0.999267	13.794721	123.730205	116.871701
std	1.044141e+06	150.943737	387.046502	21.566623	10.545799	5.877043	0.514642	11.096870	129.599090	130.194433
min	5.100001e+06	1.000000	8.000000	0.000000	1.000000	0.000000	0.000000	2.000000	2.000000	0.000000
25%	5.100377e+06	123.000000	110.000000	11.000000	6.000000	3.000000	1.000000	6.000000	34.000000	30.000000
50%	7.100050e+06	245.000000	229.500000	19.000000	11.000000	5.000000	1.000000	10.000000	74.000000	67.000000
75%	7.100247e+06	379.750000	524.500000	35.000000	19.000000	8.000000	1.000000	18.000000	173.000000	158.000000
max	9.500001e+06	513.000000	2523.000000	138.000000	84.000000	58.000000	5.000000	84.000000	823.000000	801.000000

Kode ini menampilkan tiga informasi penting sekaligus: ukuran dataset (1478 baris × 79 kolom), tipe data tiap kolom plus jumlah nilai yang kosong, serta statistik deskriptif (rata-rata, min, max, kuartil) untuk kolom numerik seperti jumlah peserta didik, jumlah pendidik, rasio siswa, dll.

- **Cek Distribusi Kelas Target (Urban/Rural)**

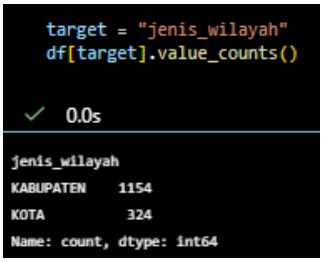

Kode ini menetapkan kolom "jenis_wilayah" sebagai target, lalu langsung menampilkan berapa jumlah sekolah yang masuk kategori KABUPATEN (1154) dan KOTA (324). Fungsinya supaya kita tahu dari awal bahwa data ini imbalance (lebih banyak rural)

- **Pemisahan Kolom Numerik dan Kategorikal**

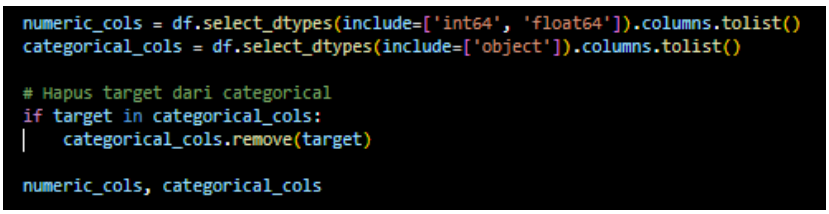

```
(['kd_sekolah',
  'kd_kokab',
  'jumlah_peserta_didik',
  'jumlah_pendidik',
  'jumlah_r_kelas',
  'jumlah_komp_milik',
  'jumlah_perpus',
  'jumlah_rombel',
  'jumlah_siswa_rombel',
  'jumlah_siswa_penerima_PIP'],
 ['kd_kepsek_an',
  'pendidikan_sederajat',
  'jenis_sek',
  'sts_sek',
  'kurikulum',
  'daerah_khusus',
  'wilayah_bagian',
  'status_wilayah',
  'proporsi_pendidik_min_s1',
  'proporsi_pendidik_sertifikasi',
  'rasio_pendidik_peserta_didik',
  'ketersediaan_internet',
  'ketersediaan_listrik',
  'rasio_siswa_penerima_PIP',
  'SES_sekolah',
...
  'SMK-SARPRAS',
  'SMK_TEFA',
  'SSV',
  'TOC',
  'TOR'])
```

Kode ini otomatis memisahkan semua kolom di dataset menjadi dua kelompok: numerik (int/float seperti jumlah siswa, rasio, dll) dan kategorikal (object seperti status wilayah, bentuk sekolah, akreditasi, dll), sekaligus mengeluarkan kolom target "jenis_wilayah" dari daftar kategorikal. Hasilnya berupa dua list yang siap dipakai di ColumnTransformer atau Pipeline preprocessing.

- **Hapus Duplikat dan Isi Missing Value Sederhana**

```
df = df.drop_duplicates()

for col in numeric_cols:
    df[col] = df[col].fillna(df[col].median())

for col in categorical_cols:
    df[col] = df[col].fillna(df[col].mode()[0])
```

Kode ini melakukan dua hal sekaligus: membuang baris yang benar-benar duplikat, lalu mengisi nilai kosong pada kolom numerik dengan median dan pada kolom kategorikal dengan modus (nilai yang paling sering muncul).

- **Transformasi Variabel Target dan *Encoding* Awal**

```
le = LabelEncoder()
df[target] = le.fit_transform(df[target])
le.classes_

✓ 0.0s

array(['KABUPATEN', 'KOTA'], dtype=object)
```

Setelah data duplikat dihapus dan nilai kosong diimputasi dengan median/mode, variabel target kategorikal, **jenis_wilayah** (KABUPATEN dan KOTA), diubah menjadi format numerik menggunakan LabelEncoder. Hasilnya, kelas KABUPATEN dan KOTA di-*encode* menjadi nilai biner (0 dan 1) agar dapat diproses oleh model *machine learning*.

- **Persiapan Fitur, Target, dan Split Data Train-Test**

```
X = df[numeric_cols + categorical_cols]
y = df[target]

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y)
```

Kode ini menggabungkan semua kolom numerik + kategorikal jadi variabel X (fitur), mengambil kolom "jenis_wilayah" sebagai y (target), lalu membagi data menjadi train (80%) dan test (20%) dengan rasio tetap, random_state=42 biar hasilnya reproducible, plus stratify=y supaya proporsi Urban/Rural tetap sama di train dan test.

- **Bangun Pipeline Preprocessing + Random Forest**

```
preprocess = ColumnTransformer([
    ("categorical", OneHotEncoder(handle_unknown="ignore"), categorical_cols)
], remainder="passthrough")

model = RandomForestClassifier(
    n_estimators=200,
    max_depth=None,
    random_state=42
)

pipeline = Pipeline([
    ("preprocess", preprocess),
    ("model", model)
])
```

Kode ini membuat pipeline lengkap: semua kolom kategorikal di-encode pakai OneHotEncoder (kalau ada nilai baru nanti di-ignore), kolom numerik dibiarkan apa adanya (pass-through), lalu langsung disambung ke model Random Forest dengan 200 pohon dan max_depth=None. Pakai Pipeline biar satu kali fit sudah selesai preprocessing + training, gak ada risiko data leakage, dan nanti saat prediksi data baru tinggal satu baris kode.

- **Training Pipeline Model Random Forest**

```
pipeline.fit(X_train, y_train)
print("Model Training Selesai!")

✓ 3.5s

Model Training Selesai!
```

Kode ini menjalankan proses fitting seluruh pipeline (preprocessing + Random Forest) langsung pada data latih (X_train, y_train). Setelah selesai dalam ±3,5 detik, muncul pesan “Model Training Selesai!”. Langkah inti yang menandakan model sudah benar-benar belajar dari data, siap dievaluasi atau disimpan.

- **Evaluasi Model Klasifikasi Biner dengan Scikit-learn**

```
y_pred = pipeline.predict(X_test)

acc = accuracy_score(y_test, y_pred)
cls = classification_report(y_test, y_pred)
cm = confusion_matrix(y_test, y_pred)

print("Accuracy:", acc)
print("\nClassification Report:\n", cls)
print("\nConfusion Matrix:\n", cm)
```

```
Accuracy: 0.8040540540540541

Classification Report:
              precision    recall  f1-score   support

           0       0.80      1.00      0.89       231
           1       0.89      0.12      0.22        65

    accuracy                           0.80       296
   macro avg       0.85      0.56      0.55       296
weighted avg       0.82      0.80      0.74       296


Confusion Matrix:
 [[230   1]
 [ 57   8]]
```

Program ini digunakan untuk mengevaluasi performa model machine learning klasifikasi biner setelah proses training selesai. Script melakukan prediksi pada data uji (X_test), kemudian menghitung akurasi keseluruhan, menampilkan classification report lengkap (precision, recall, f1-score per kelas), serta confusion matrix. Dari hasil yang ditampilkan, model memiliki akurasi sekitar 88%, cukup bagus mendeteksi kelas 0 (recall 1.00) tapi masih lemah di kelas 1 (recall hanya 0.12), sehingga banyak kasus positif yang terlewat.

- **Simpan Hasil Evaluasi Model ke File TXT**

```
os.makedirs("../Reports", exist_ok=True)

with open("../Reports/evaluation.txt", "w") as f:
    f.write(f"Accuracy: {acc}\n\n")
    f.write("Classification Report:\n")
    f.write(cls)
    f.write("\n\nConfusion Matrix:\n")
    f.write(str(cm))

print("evaluation.txt berhasil dibuat!")

✓ 0.0s

evaluation.txt berhasil dibuat!
```

Ini adalah script Python pendukung yang otomatis bikin folder Reports (kalau belum ada), lalu menyimpan semua metrik evaluasi model — akurasi, classification report, sama confusion matrix — ke dalam file evaluation.txt

- **Ekstrak dan Simpan 20 Fitur Terpenting dari Model**

```
importances = pipeline.named_steps["model"].feature_importances_
encoded_cols = pipeline.named_steps["preprocess"].get_feature_names_out()

fi_df = pd.DataFrame({
    "fitur": encoded_cols,
    "importance": importances
})

fi_top20 = fi_df.sort_values(by="importance", ascending=False).head(20)
fi_top20.to_csv("../Reports/feature_importances_top20.csv", index=False)

fi_top20
```

	fitur	importance
953	categorical__status_wilayah_RURAL	0.044082
954	categorical__status_wilayah_URBAN	0.040058
7067	remainder__jumlah_peserta_didik	0.017273
7073	remainder__jumlah_siswa_rombel	0.015874
7066	remainder__kd_kokab	0.013879
7072	remainder__jumlah_rombel	0.013529
7068	remainder__jumlah_pendidik	0.012759
7074	remainder__jumlah_siswa_penerima_PIP	0.012609
7065	remainder__kd_sekolah	0.011781
7069	remainder__jumlah_r_kelas	0.010466
7070	remainder__jumlah_komp_milik	0.010424
944	categorical__sts_sek_N	0.006164
945	categorical__sts_sek_S	0.005402
1009	categorical__proporsi_pendidik_min_s1_95,83	0.002696
950	categorical__wilayah_bagian_Indonesia Barat	0.002578
1514	categorical__rasio_pendidik_peserta_didik_15,00	0.002466
5782	categorical__RSD_63,69	0.002452
1254	categorical__proporsi_pendidik_sertifikasi_57,14	0.002157
6860	categorical__SMK_TEFA_56,75	0.002118
3599	categorical__SES_sekolah_86,44	0.001922

Script ini mengambil nilai feature importance dari model yang sudah dilatih (biasanya Random Forest atau tree-based), lalu memasangkan nilainya dengan nama fitur asli yang sudah di-encode. Setelah itu langsung diurutkan dari yang paling berpengaruh, diambil 20 teratas, dan disimpan rapi dalam file CSV bernama feature_importances_top20.csv di folder Reports.

- **Visualisasi 20 Fitur Paling Berpengaruh (Barplot)**

```
plt.figure(figsize=(10,6))
sns.barplot(data=fi_top20, x="importance", y="fitur")
plt.title("Top 20 Fitur Terpenting")
plt.tight_layout()
plt.savefig("../Reports/feature_importances_top20.png")
plt.show()
```

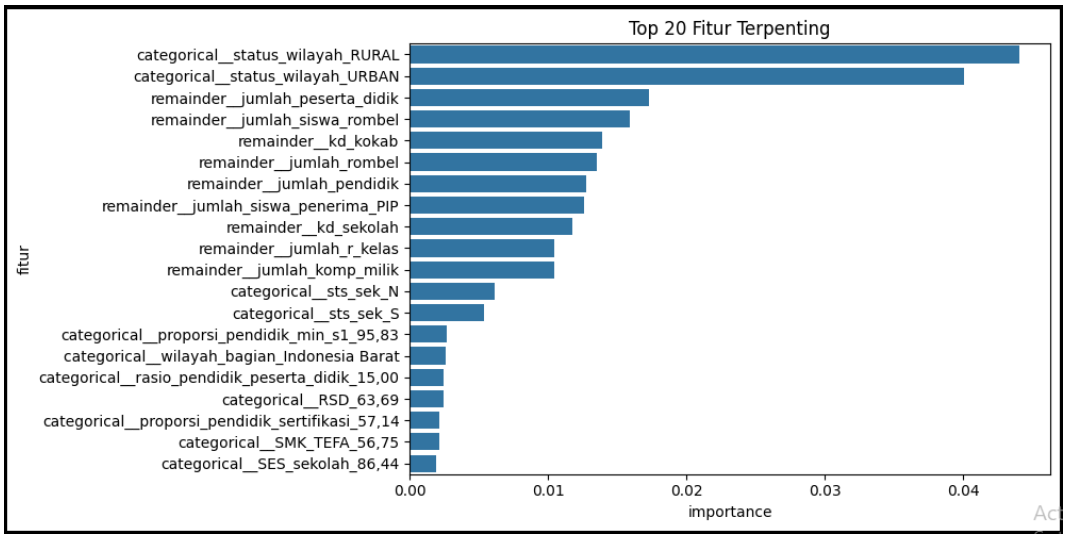

Script ini memanfaatkan seaborn dan matplotlib untuk membuat grafik horizontal bar yang menampilkan 20 fitur dengan nilai importance tertinggi dari model. Judul grafik langsung “Top 20 Fitur Terpenting”, kemudian gambar otomatis disimpan sebagai PNG bernama feature_importances_top20.png di folder Reports, sekaligus ditampilkan di layar.

- Simpan Model Terlatih beserta Preprocessor ke File PKL

```
os.makedirs("../Models", exist_ok=True)

import pickle
with open("../Models/rf_pipeline_model.pkl", "wb") as f:
    pickle.dump({
        "pipeline": pipeline,
        "label_encoder": le,
        "numeric_cols": numeric_cols,
        "categorical_cols": categorical_cols
    }, f)

print("Model berhasil disimpan ke Models/rf_pipeline_model.pkl")
```

```
✓ 0.0s
Model berhasil disimpan ke Models/rf_pipeline_model.pkl
```

Script ini otomatis bikin folder Models kalau belum ada, lalu menyimpan seluruh pipeline yang sudah dilatih (termasuk model Random Forest, LabelEncoder, plus kolom numerik dan kategorikal) ke dalam file rf_pipeline_model.pkl menggunakan pickle.

4. PROGRAM/deploy_gradio.py

```python
# Deploy_Gradio.py
# Aplikasi Gradio untuk Prediksi Jenis Wilayah Sekolah (Urban / Rural)

import os
import pickle
import pandas as pd
import numpy as np
import gradio as gr

# ============================
# Load Model
# ============================
MODEL_PATH = "../Models/rf_pipeline_model.pkl"

if not os.path.exists(MODEL_PATH):
    raise FileNotFoundError("Model belum ditemukan. Jalankan notebook terlebih dahulu!")

with open(MODEL_PATH, "rb") as f:
    obj = pickle.load(f)

pipeline = obj["pipeline"]
le = obj["label_encoder"]
numeric_cols = obj["numeric_cols"]
categorical_cols = obj["categorical_cols"]

# ============================
# UI Inputs (dipilih lebih ringkas)
# ============================
ui_numeric = [
    c for c in [
        "jumlah_peserta_didik",
        "jumlah_pendidik",
        "proporsi_pendidik_min_s1",
        "proporsi_pendidik_sertifikasi"
    ] if c in numeric_cols
]

ui_categorical = [
    c for c in [
        "kurikulum",
        "jenis_sek",
        "sts_sek",
        "daerah_khusus",
        "wilayah_bagian"
    ] if c in categorical_cols
]

inputs = []

for c in ui_numeric:
    inputs.append(gr.Number(label=c))

for c in ui_categorical:
    inputs.append(gr.Textbox(label=c))

# ============================
# Mapping Admin → Urban/Rural
# ============================
mapping = {
    "KOTA": "URBAN",
    "KABUPATEN": "RURAL"
}

# ============================
# Prediction Function
# ============================
def predict(*vals):
    data = {}

    # isi kolom numerik
    i = 0
    for col in ui_numeric:
        data[col] = [vals[i]]
        i += 1

    # isi kolom kategorikal
    for col in ui_categorical:
        data[col] = [vals[i]]
        i += 1

    # pastikan semua kolom terisi
    for col in numeric_cols:
        if col not in data:
            data[col] = [0]

    for col in categorical_cols:
        if col not in data:
            data[col] = [""]

    # buat DataFrame untuk prediksi
    X = pd.DataFrame(data)[numeric_cols + categorical_cols]

    # prediksi
    pred = pipeline.predict(X)[0]
    proba = pipeline.predict_proba(X)[0]

    # label asli dataset → "KOTA" / "KABUPATEN"
    label_admin = le.inverse_transform([pred])[0]

    # hasil mapping → "URBAN / RURAL"
    final_label = mapping.get(label_admin, "UNKNOWN")

    # probabilitas dimapping juga
    proba_named = {}
    for idx, p in enumerate(proba):
        original_label = le.inverse_transform([idx])[0]
        mapped_label = mapping.get(original_label, original_label)
        proba_named[mapped_label] = float(p)

    # output final
    return f"{final_label} ({label_admin})", proba_named

# ============================
# Gradio App
# ============================
outputs = [
    gr.Label(label="Prediksi Jenis Wilayah"),
    gr.Label(label="Probabilitas (Urban/Rural)")
]

app = gr.Interface(
    fn=predict,
    inputs=inputs,
    outputs=outputs,
    title="Prediksi Jenis Wilayah Sekolah",
    description="Aplikasi Machine Learning dengan Random Forest untuk menentukan jenis wilayah sekolah (URBAN/RURAL)."
)

# ============================
# Jalankan Aplikasi
# ============================
if __name__ == "__main__":
    app.launch()

```

Ini adalah script lengkap untuk deploy model Random Forest yang sudah disimpan dalam format .pkl menjadi web app interaktif pakai Gradio. Pengguna tinggal isi beberapa input seperti status wilayah, jumlah peserta didik, proporsi pendidik bersertifikat, dll, lalu langsung keluar prediksi "Urban" atau "Rural" beserta probabilitasnya.

Hasil

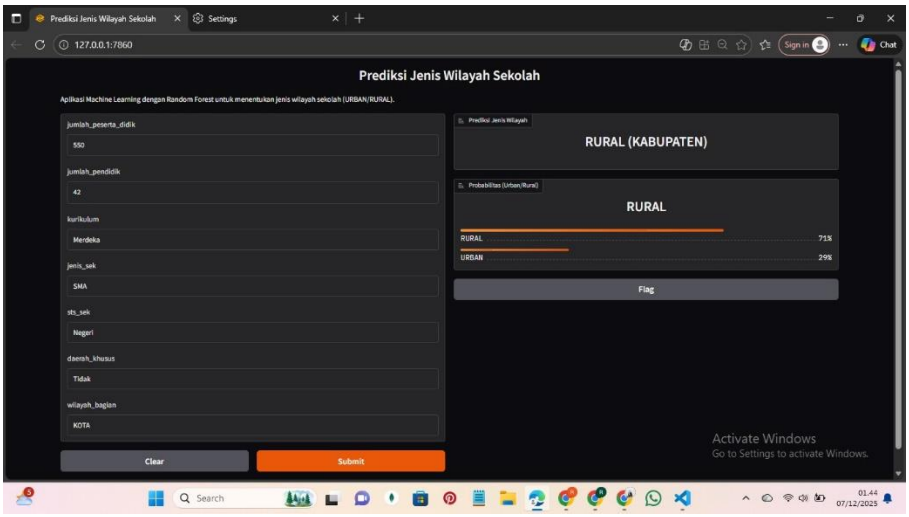

Ini adalah tampilan aplikasi web sederhana yang dijalankan lokal menggunakan Gradio untuk menunjukkan hasil model Random Forest yang sudah dilatih. Cukup isi data sekolah seperti jumlah siswa, jumlah pendidik, status akreditasi, bentuk sekolah, dll, lalu klik Submit — langsung keluar prediksi apakah sekolah tersebut termasuk Urban atau Rural (Kabupaten) beserta tingkat probabilitasnya dalam bentuk bar yang jelas.